

Estudo de Caso 2: Métodos de Projeção

Pós-Graduação e MBA: Analytics, Inteligência Artificial e Data Science

Prof. Ângelo Chiode

Julho de 2025

Case: Potencial de Novos Clientes

Contexto: Uma rede de lojas de departamento deseja estimar o gasto potencial de novos clientes ao adquirirem o cartão exclusivo da loja (*private label*) ao longo de 12 meses, contabilizado após 3 meses de posse do cartão.

Motivação: Direcionar ações de aquisição e ativação de clientes com maior propensão a gerar receita, ajustar limites de crédito iniciais e definir estratégias de comunicação com base no perfil de consumo esperado.

Dados: A área de Produtos forneceu de uma base de dados na **visão cartão** – ou visão cliente, considerando que cada indivíduo só pode ser portador de um único cartão). O nome do arquivo com os dados é `Potencial_Novos_Clientes.txt`. As seguintes variáveis estão disponíveis:

- **COD_CARTAO:** Código de identificação do cartão.
- **IDADE_CLIENTE:** Idade do cliente, em anos.
- **RENDA_MENSAL_CLIENTE:** Renda mensal declarada pelo cliente, em R\$.
- **BEHAVIOUR_SCORE_CLIENTE:** Behaviour score do cliente (avalia o comportamento financeiro e de consumo como um todo).
- **QTD_TRANSACOES_3M:** Quantidade de transações realizadas no cartão, nos 3 primeiros meses de posse.
- **QTD_ITENS_3M:** Quantidade de itens comprados no cartão em lojas da rede, nos 3 primeiros meses de posse.

- **VALOR_GASTO_3M**: Valor total gasto no cartão, nos 3 primeiros meses de posse.
- **TICKET_MEDIO_3M**: Valor médio gasto em transações no cartão, nos 3 primeiros meses de posse.
- **FLAG_ALTO_CUSTO_3M**: Indica se o cliente realizou alguma compra em estabelecimentos considerados de alto custo, nos 3 primeiros meses de posse.
- **SATISFACAO_CARTAO**: Nível de satisfação do cliente em relação ao cartão, em pesquisa de participação não obrigatória.
- **VALOR_GASTO_PROX_12M**: Valor total gasto no cartão, nos 12 meses seguintes.

Questões

1. (1 ponto) Realize uma análise bivariada para examinar graficamente a existência de associação entre a variável resposta e cada uma das variáveis explicativas. Escolha os gráficos apropriados para cada situação. Interprete todos os gráficos gerados.
2. (1 ponto) Calcule os índices de correlação linear de Pearson para todos os pares de variáveis quantitativas presentes na base de dados. Responda as seguintes questões:
 - (a) Quais as duas variáveis explicativas **mais** correlacionadas com a variável resposta? Para cada uma delas, o fato de as correlações serem altas é coerente do ponto de vista de negócio? Por quê?
 - (b) Quais as duas variáveis explicativas **menos** correlacionadas com a variável resposta? Para cada uma delas, o fato de as correlações serem baixas é coerente do ponto de vista de negócio? Por quê?
 - (c) Quais as duas variáveis explicativas **mais** correlacionadas **entre si**? O que essa correlação indica do ponto de vista de negócio?
3. (1 ponto) Crie *dummies* para as variáveis qualitativas e construa um modelo de regressão linear múltipla, considerando nível de significância de 3% e seleção manual de variáveis via *stepwise backward*. Neste momento, não avalie colinearidade. Interprete os coeficientes estimados de cada uma das variáveis que se mostrarem estatisticamente significativas, bem como o intercepto.
4. (1 ponto) Por meio de índices VIF, avalie se existem indícios de colinearidade no modelo obtido no item anterior. Comente os resultados. **Observação:** Não realize novos ajustes de modelo, mesmo que haja colinearidade.

5. (1 ponto) Elabore gráficos de resíduos do modelo e calcule as distâncias de Cook. Os resíduos atendem às premissas de normalidade e homocedasticidade? Além disso, existem pontos influentes?
6. (1 ponto) Divida a base de dados original em conjuntos de treino (75%) e teste externo (25%), usando a semente aleatória 123. Considerando todas as variáveis explicativas disponíveis, desenvolva o pré-processamento no conjunto de treino: para variáveis qualitativas, transforme-as utilizando codificação *one-hot*; e para variáveis quantitativas, padronize as escalas utilizando o método *z-score*. Aplique as transformações no conjunto de teste externo. Por quais motivos esses dois tipos de tratamentos são necessários?
7. (1,5 ponto) Considere as seguintes classes de algoritmos de projeção:
 - Regressão linear com regularização (Ridge, LASSO, ElasticNet)
 - Árvore de regressão
 - Floresta aleatória
 - Impulsioneamento (AdaBoost, *gradient boosting*, *histogram-based gradient boosting*, XGBoost e LightGBM)

Para cada algoritmo, defina os intervalos de valores para busca de hiperparâmetros, seguindo os **mesmos padrões estabelecidos nos materiais de aula** (tanto no que diz respeito à escolha dos hiperparâmetros que serão otimizados, quanto aos seus intervalos de valores), com **exceção** das seguintes alterações:

- Quantidade de iterações: entre **10** e **500**
(em todos os algoritmos aplicáveis)
- Tamanho mínimo dos nós pais: entre **100** e **200** observações
(em todos os algoritmos aplicáveis)
- Tamanho mínimo dos nós filhos: entre **50** e **100** observações
(em todos os algoritmos aplicáveis)
- Qtde. máxima de nós finais: entre **10** e **20**
(em todos os algoritmos aplicáveis)
- Profundidade máxima: entre **2** e **8** níveis
(em todos os algoritmos aplicáveis)

Observação: Não considere o algoritmo de regressão linear estimada via gradiente descendente (SGD), que apresenta problemas de convergência para esta base de dados.

Em seguida, utilizando validação cruzada com $k = 10$ *folds* e 50 iterações de busca aleatória (*randomized search*), realize o ajuste de diferentes modelos via *scikit-learn*, visando minimizar o erro quadrático médio. Considere a semente aleatória 123 nas definições de todos os algoritmos (exceto Ridge), na definição da validação cruzada e na função de busca aleatória.

Armazene os resultados de RMSE médio de treino, RMSE médio de teste interno e RMSE de teste externo. Analisando os resultados obtidos, escolha um algoritmo/modelo final e especifique os valores dos seus hiperparâmetros. Por quê você escolheu este modelo?

8. (0,5 ponto) No conjunto de teste externo, calcule o RMSE, MAE, MAPE e R^2 do modelo obtido no item (7). Examine, também, o comportamento gráfico dos resíduos. Interprete todos os resultados gerados.
9. (1 ponto) Avalie o grau de importância das variáveis no modelo obtido no item (7), de acordo com:
 - Redução de impureza (caso se trate de um modelo baseado em árvores)
 - Permutação
 - Valores SHAP

Os métodos apontam para conclusões semelhantes?

10. (1 ponto) A partir dos valores SHAP, interprete as direções das relações exercidas pelas cinco principais variáveis explicativas. Elas são coerentes com a análise bivariada e com a visão de negócio?